编译原理小组作业：基于 Lex 和 Yacc 的 C to Python 编译器

组员：吴佳龙 赵伊书杰 黄舒炜

开发环境与使用说明

项目说明

操作系统：Ubuntu 16.04（运行在虚拟机上）

Python版本：Python 3.7

团队开发管理：Github, HedgeDoc

文件目录结构：

```
.
├── bin
|   ├── parser # 可在Linux下运行的编译器
|   ├── README.md # 运行说明
|   └── utils.py # 运行组件
├── doc
|   └── report.pdf # 此报告
└── src
    ├── examples
    |   └── 测试用例
    └── 项目代码主要文件
```

编译与运行方法：

```
$ cd src
$ make clean
$ make
$ ./parser [Input C File]
$ python out.py
```

若缺省输入文件，则默认编译同级目录下的 `in.c` 文件。（可在/src/examples下找到更多测试用例）

语法支持情况

本次作业支持C语言的大部分常见语法，具体说来，包括：**常量、变量、算术与逻辑表达式、条件与循环语句、一维数组、函数及其参数的定义与使用**，包括对其**作用域的检测与判断。**除此之外，还支持部分**常见错误的检测。**

但是，下面的语法特性是不支持的：**指针与引用**（Python中并没有相关概念），**高维数组**，**continue, break和do - while语句**，**在if/while语句中使用单独的变量**作为判断条件。

错误检测与处理

本次作业除了编译正常的C代码外，还能对部分常见错误进行检测与报错处理，如：**词法和语法错误**，**变量、数组的重定义或未定义**，**函数的重定义或未定义。**其中，对于重定义和未定义的错误，我们支持在遇见错误的情况下**继续对余下部分编译**，并在编译完成后统一给出提示信息，使得用户能够在一次编译过程中发现尽可能多的错误。

技术方案

本次作业分别使用Lex和Yacc作为词法和语法分析器，并通过对Yacc返回的抽象语法树(AST)进行遍历和解析，维护了符号表、完成了目标代码的生成和错误处理。详见下文。

亮点与难点

库函数的翻译：`scanf` 和 `printf` 等

由于 C 中的库函数在 Python 没有对应，因此我们用 Python 语言额外实现了示例程序用到的 C 函数，包括 `scanf`, `printf`, `atoi`, `strlen`，放在 `utils.py` 中，并通过在生成的目标 Python 程序中 `from utils import *` 来使用。以下说明两个难点函数的 Python 实现。

`scanf` 的 Python 实现

首先将 `scanf` 的格式化字符串中的限定符 `%d` 和 `%s` 转为相应的正则表达式 `([-+]?\d+)` 和 `(\S+)`，并通过正则匹配从输入中读取相应的值。此外，由于解释型语言 Python 的输入方法 `input()` 是逐行读入的，我们还实现了*输入缓冲区*，当正则匹配不能匹配到所有想要的值时，就新读取一行加入缓冲区，重新匹配。

调用方法：目前支持格式化字符串中仅含限定符 `%d` 和 `%s` 并且**必须用空格分割。**对于 `%d`，返回数值类型；对于 `%s` ，返回的是长度为 1 的 `str` （视为一个字符）的 `list`。

```
< scanf("%s%d", a, &b);
---
> [a, b] = scanf("%s %d")
```

`printf` 的 Python 实现

使用 Python 中的格式化字符串实现。调用方式与 C 中稍有不同：

```
< printf("a=%s, b=%d, c=%d, d=%d", a, b, c, d);     // C
---
> printf("a=%s, b=%d, c=%d, d=%d", (a, b, c, d))    // utils.py
```

语义分析

变量、函数的重定义(未定义)检查

本次作业中，通过对符号表的维护，我们支持识别每个变量的定义情况及其所在的作用域。当用户试图引用一个变量时，程序将从当前所在作用域开始，从栈顶向栈底逐层移动，直到找到某个同名变量，就返回其信息。或者，如果程序在移动到栈底（对应于全局变量）时仍无法找到该变量，就记录一个变量未定义错误，并继续编译流程。

检查重定义的思路与检查未定义是相似的，只不过此时程序只需要检查当前所在的作用域（而不必在栈中向下移动）是否已有同名变量，并对同名变量报错即可。

由于C语言不支持在函数体内另外定义新的函数，因此我们没有必要对函数维护作用域栈。只需要维护一个全局的函数符号表进行查询和删改即可。

变量的作用域检查及其重命名

正如上一节中所描述的那样，除了符号表的管理，程序还在编译时动态维护了一个作用域栈。栈顶指向了编译器当前所在的作用域，从栈顶向下移动，作用域逐渐扩大，直到达到全局作用域。对于变量的引用，只需要从栈中检查是否已有同名变量即可判断引用是否合法。而对于变量的定义，可能会遇见以下三种情况：

- 在整个栈中都没能找到该变量的定义

  此时，变量是第一次定义，只需要将其加入当前所在的作用域即可。

- 在当前作用域栈帧找到了该变量的定义

  此时，变量重定义，产生合适的报错信息即可。

- 在当前作用域栈帧没能找到该变量的定义，但在更早的栈帧中找到了同名变量的定义。

  此时，变量没有重定义。但由于Python的语法特性，我们需要将更早栈帧中定义的变量与当前栈帧中的变量名区分开，以避免误操作外部变量。对这一问题的解决方案是将当前变量重命名，并同时保存该变量的原名称和新名称。每当引用一个变量时，我们就通过比较原名称的方式在栈中查找该变量。但是，一旦找到所需的变量，我们会返回其新名称，以避免对外部变量的误操作。

具体示例请见下节的“变量重命名示例”部分。

测试程序

回文检测

```
$ ./parser examples/palindrome.c
```

输入字符串，输出 True 或者 False

测试样例：

```
# Sample 1
In[1]:
    palindrome
Out[1]:
    False
# Sample 2
In[2]:
    abcba
Out[2]:
    True
```

四则运算计算

```
$ ./parser examples/calc.c
```

支持的四则运算表达式：

支持的四则运算表达式可由文法$G[Expr]$描述（不支持包含空格的表达式）：

$$
\begin{aligned}
Expr &\rightarrow Expr\ Op\ Expr \\
Expr &\rightarrow Sign\ (Expr) \\
Expr &\rightarrow number \\
Op &\rightarrow + \mid - \mid \times \mid \div \\
Sign &\rightarrow + \mid - \mid \varepsilon
\end{aligned}
$$

测试样例：

```
# Sample 1
```

```
In[1]:
    -1*-(2+3)
Out[1]:
    5.000000
# Sample 2
In[2]:
    4/(3*2)
Out[2]:
    0.666667
# Sample 3
In[3]:
    -(+(-(+(-3))))/2+5*(-2)
Out[3]:
    -11.500000
```

语法检查示例

```
$ ./parser examples/special.c
```

语法错误说明：

- 第9行重复定义函数func1（第3行已定义）
- 第16行重复定义变量a（第14行已定义）
- 第17行使用未定义的变量b
- 第19行使用未定义的变量b
- 第19行使用未定义的函数func2
- 第22行重复定义数组变量arr

运行结果：

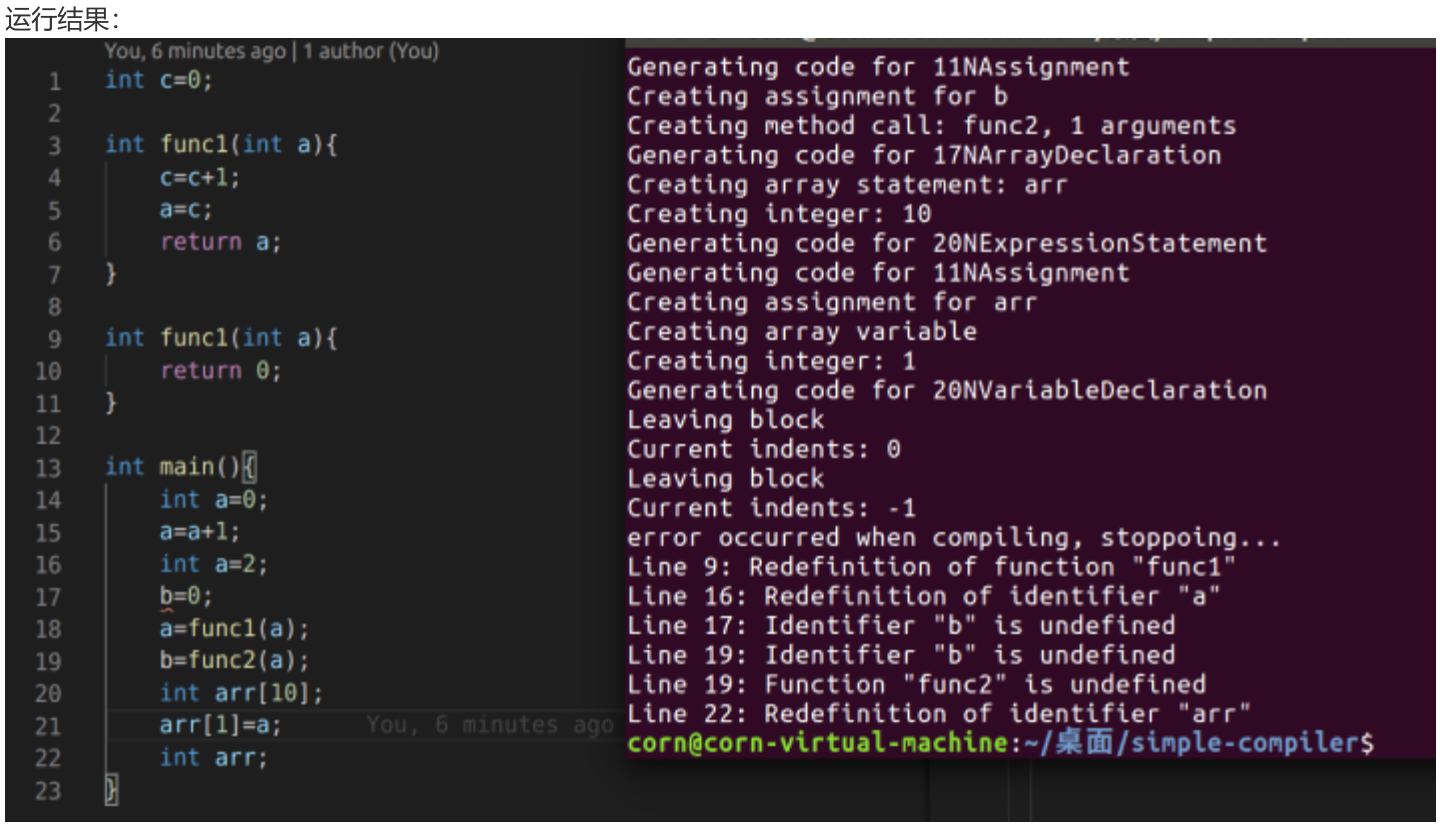

变量重命名示例

```
$ ./parser examples/test.c
```

重命名说明（括号外的行号为原c代码，括号中的行号为翻译后的python代码）：

- 程序多处使用变量名为a的变量，对不同的变量进行重命名
- 第1行（第3行）为全局变量，使用原名**a**，改变量在第8行（第10行）中使用
- 第3行（第4行）函数参数重命名为**a_1**，该变量在第4行（第6行）中使用
- 第9行（第11行）在main中定义变量a，该变量为局部变量，重命名为**a_2**，在第10、16、17行（12、17、18行）中使用
- 第11行（第11行）定义变量，使用原命名**a_4**，在第11行（第14、16行）中使用
- 第12行（第15行）定义变量并使用，重命名为**a_5**

运行结果（左边为原c代码，右边为翻译后的python代码）：

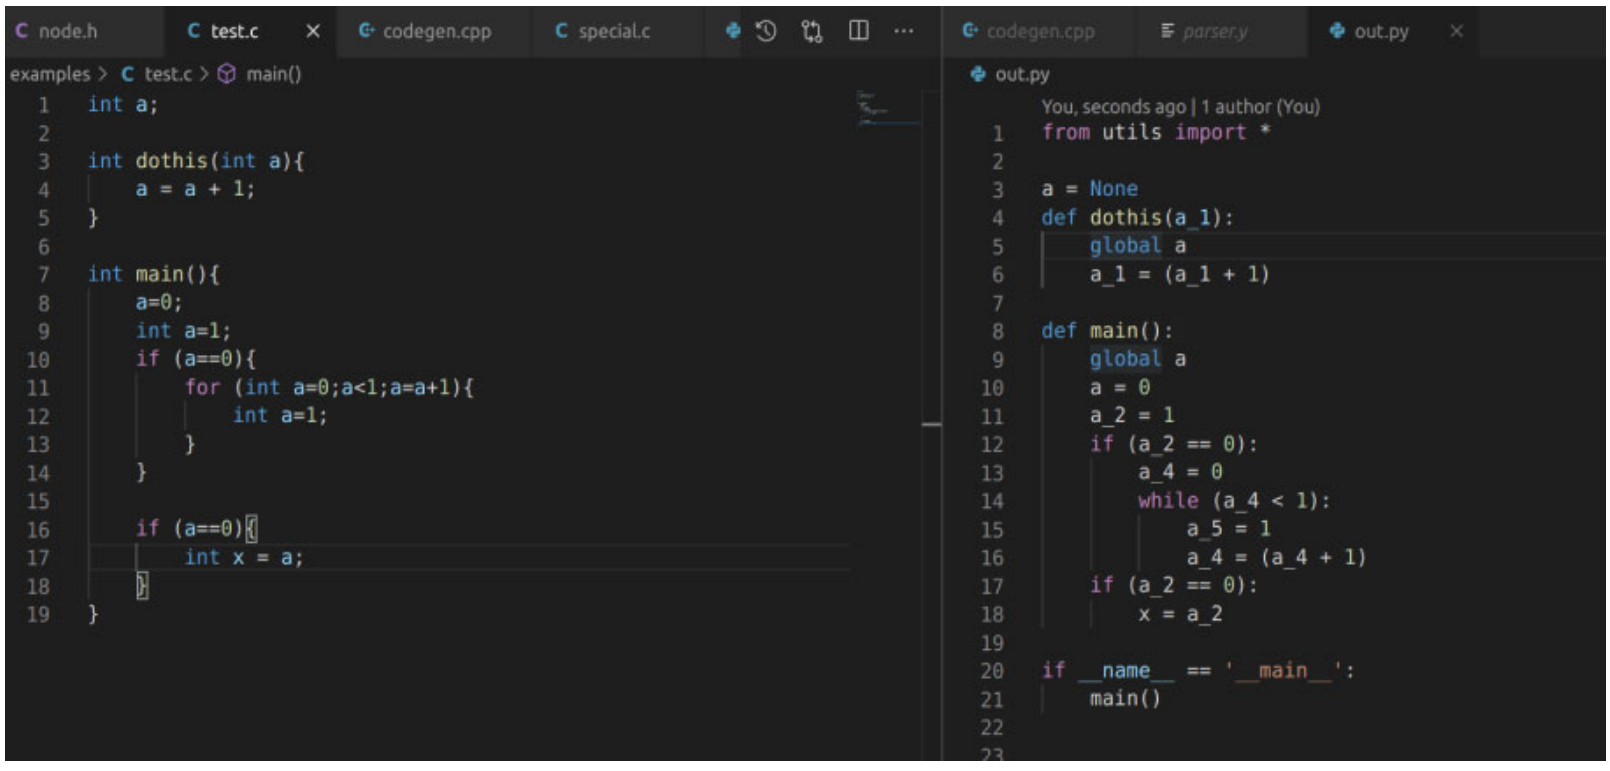

分工

吴佳龙:

- Lex 和 Yacc 的技术调研
- 实现词法分析和语法分析，支持**除数组外**大部分基本语法
- 支持编译错误信息显示行号
- 示例程序（回文检测和四则运算）的编写和正确性验证

赵伊书杰:

- 一维数组的实现
- 部分语义识别与错误检测
- 部分程序测试、语法部分Bug修复与完善
- 文档撰写

黄舒炜:

- 语法检查，对变量/函数的未定义使用/重定义进行检查
- 变量重命名，对同名不同作用域的变量进行重命名
- 错误处理示例程序编写及验证
- 示例程序（四则运算）的测试

参考资料

- Write text parsers with yacc and lex – IBM Developer
- Writing Your Own Toy Compiler Using Flex, Bison and LLVM (gnuu.org)
- re — Regular expression operations — Python 3.9.1 documentation